

كيف تساعد المصادر الفريق؟

تم اختيار هذه المصادر لتدعم الفرق في مراحل مختلفة من تطوير الحل، بغض النظر عن تقنية الذكاء الاصطناعي التي ستختارها. يمكن للفريق الرجوع إلى المصادر المناسبة حسب المشكلة والبيانات وطريقة الحل:

- فهم أساسيات AI و Machine Learning: تساعد المصادر العربية و Google ML Crash Course الفرق على فهم المفاهيم الأساسية واختيار الأسلوب المناسب للمشكلة.
- التعامل مع البيانات: توفر NASA Earthdata و NASA Worldview وموارد البيانات الأخرى أمثلة وبيانات حقيقية يمكن استخدامها عندما يحتاج الحل إلى بيانات فضائية أو Earth Observation.
- تحليل البيانات وبناء النماذج: يمكن استخدام أدوات مثل Google Colab و Scikit-learn لتجهيز البيانات، تحليلها، تدريب النماذج واختبارها بسرعة.
- Computer Vision: إذا كان الحل يعتمد على الصور، يمكن استخدام Hugging Face و Datasets ومراجع Satellite Deep Learning لتطبيق Classification أو Detection أو Segmentation.
- Astronomical Data: إذا كان التحدي يحتاج إلى بيانات فلكية، يمكن استخدام Astropy وأدوات البيانات الفلكية المناسبة.
- Generative AI / AI Applications: يمكن للفريق استخدام المصادر كمرجع لفهم البيانات والمشكلة، ثم اختيار الأدوات والنماذج المناسبة لبناء تطبيق أو Prototype يعتمد على Generative AI أو LLMs عند الحاجة.
- Automation & Predictive Systems: يمكن استخدام نفس الموارد لفهم البيانات وبناء pipelines أو نماذج تنبؤية وأتمتة أجزاء من الحل، حسب طبيعة المشكلة.
- Research & Inspiration: توفر FreeDSM و LightViz أمثلة على كيفية تحويل مشكلة واقعية إلى حل تقني، ويمكن الاستفادة منهما للإلهام وليس كحلول جاهزة.

ملحوظة => لا يُطلب من الفرق استخدام جميع المصادر أو اتباع ترتيب محدد. يُنصح كل فريق باختيار المصادر التي تتناسب مع طبيعة المشكلة، نوع البيانات، مستوى الفريق، وتقنية الذكاء الاصطناعي التي اختارها.

أولاً: مصادر ما قبل الهاكاثون Preparation من 20 ل 25 سبتمبر

1. Google Machine Learning Crash Course

[Google ML Crash Course](#)

- المستوى: Beginner → Intermediate
- الهدف: فهم أساسيات Machine Learning بطريقة عملية.
- نتعلم منه: Classification, Regression, Neural Networks, Data Preparation, Model Evaluation.
- مناسب لمين؟ الشخص الذي يعرف Python basics ويريد تأسيس نفسه في ML.
- أثناء الهاكاثون؟ كمرجع محدود، وليس للتعلم من البداية.

2. تعلم الآلة بالعربي — YouTube

[تعلم الآلة بالعربي](#)

- المستوى: Beginner
- الهدف: فهم Machine Learning باللغة العربية.
- مناسب لمين؟ المبتدئين الذين يجدون المحتوى الإنجليزي صعباً.
- يساعدك في: فهم المفاهيم الأساسية قبل الانتقال للتطبيق.
- ملاحظة: لا تحتاج لمشاهدة السلسلة كاملة إذا كان وقتك محدوداً.

3. NASA ARSET

[NASA ARSET Training](#)

- المستوى: Beginner → Advanced حسب التدريب.
- الهدف: فهم كيفية استخدام بيانات الاستشعار عن بُعد وبيانات NASA في مشكلات حقيقية.
- نتعلم منه: Remote Sensing, Satellite Data, Earth Observation, وتحليل البيانات.
- مناسب لمين؟ الفرق التي ستستخدم Satellite/Earth Observation data.
- متى تستخدمه؟ قبل الهاكاثون لفهم المجال، ويمكن الرجوع إليه أثناء الهاكاثون.

4. NASA ARSET — Air Pollution

[Inside Look at How NASA Measures Air Pollution](#)

- الهدف: مثال عملي على استخدام بيانات الأقمار الصناعية لدراسة مشكلة بيئية.
- نتعلم منه: كيف تُستخدم بيانات NASA في مراقبة وتحليل التلوث.
- مناسب لمين؟ من يريد فهم العلاقة بين Satellite Data والمشكلات الواقعية.

Machine Learning on Satellite Imagery — UN SDG Learn .5

[Machine Learning on Satellite Imagery](#)

- المستوى: Intermediate
 - الهدف: الربط بين Machine Learning و Satellite Imagery.
 - هتتعلم منه: كيفية استخدام ML مع بيانات وصور الأقمار الصناعية.
 - مناسب لمين؟ من لديه أساسيات ML ويريد تطبيقها على Space/Earth Observation.
-

Hugging Face Computer Vision .6

[Hugging Face Computer Vision Course](#)

- المستوى: Intermediate
 - الهدف: تعلم استخدام AI في تحليل الصور.
 - هتتعلم منه: Image Classification، Object Detection، Segmentation، Deep Learning Models.
 - مناسب لمين؟ الفرق التي تفكر في حل يعتمد على الصور.
 - متى تستخدمه؟ قبل الهاكاثون أو كمرجع أثناءه.
-

Astropy .7

[Astropy Documentation](#)

- المستوى: Intermediate
 - الهدف: التعامل مع البيانات الفلكية باستخدام Python.
 - هتتعلم منه: التعامل مع astronomical data، coordinates، FITS وغيرها.
 - مناسب لمين؟ الفرق التي تعمل على Astronomy/Astrophysics data وليس فقط Earth Observation.
 - متى تستخدمه؟ قبل أو أثناء الهاكاثون حسب طبيعة المشروع.
-

ثانيًا: مصادر أثناء الهاكاثون (Build & Reference)

Google Colab .8

[Google Colab](#)

- النوع: Coding Environment
- الهدف: كتابة وتشغيل Python و ML مباشرة من المتصفح.

- الميزة: لا تحتاج إلى إعداد بيئة Python كاملة على الجهاز.
 - مناسب لمين؟ جميع الفرق التي تحتاج إلى Coding.
 - الاستخدام: Data Analysis → ML → Visualization → Prototyping.
-

9. Scikit-learn

[Scikit-learn Documentation](#)

- النوع: ML Library + Documentation
 - الهدف: تنفيذ نماذج Machine Learning بسرعة.
 - تقدر تستخدمه في: Classification, Regression, Clustering, Preprocessing, Evaluation.
 - الميزة: بدل مشاهدة درس طويل، ابحث عن الـ function أو الـ algorithm الذي تحتاجه.
 - مناسب لمين؟ أي فريق يستخدم ML على بيانات منظمة أو features.
-

10. NASA Earthdata Search

[NASA Earthdata Search](#)

- النوع: Data Discovery Platform
 - الهدف: البحث عن بيانات NASA المناسبة للمشروع.
 - تستخدمه عندما: تحتاج Dataset حقيقي بدل Dataset تجريبي.
 - مناسب لمين؟ الفرق التي تحتاج Earth/Satellite/Environmental data.
 - متى تستخدمه؟ أثناء اختيار البيانات وأثناء تطوير المشروع.
-

11. NASA Worldview

[NASA Worldview](#)

- النوع: Satellite Data Visualization
- الهدف: استكشاف صور وبيانات الأقمار الصناعية بصريًا.
- تقدر تستخدمه في: اختيار مناطق، مقارنة تواريخ، فهم نوع الـ imagery المتاح.
- مناسب لمين؟ فرق Satellite/Earth Observation.
- متى تستخدمه؟ أثناء البحث عن البيانات وتحديد فكرة المشروع.

12. NASA Nighttime Lights

[NASA Nighttime Lights](#)

- النوع: NASA Data Resource
 - الهدف: الوصول إلى بيانات الإضاءة الليلية وتحليلها.
 - مفيد في: Light Pollution، Urbanization، Human Activity وغيرها.
 - مناسب لمين؟ الفرق التي تختار مشكلة مرتبطة بالـ nighttime observations.
 - متى تستخدمه؟ أثناء الهاكاثون إذا كان مناسباً للمشكلة.
-

13. Kaggle — Semantic Segmentation Dataset

[Semantic Segmentation of Aerial Imagery](#)

- النوع: Dataset
 - الهدف: تجربة Computer Vision على صور جوية/فضائية.
 - مفيد في: Computer Vision و Image Segmentation.
 - الميزة: Dataset جاهز للتجربة بدل إضاعة وقت في جمع البيانات.
 - مناسب لمين؟ الفرق التي تحتاج Dataset سريع لتجربة الـ prototype.
 - متى تستخدمه؟ أثناء الهاكاثون.
-

14. Satellite Image Deep Learning — GitHub

[Satellite Image Deep Learning Techniques](#)

- النوع: Technical Reference
 - الهدف: البحث عن تقنيات وأمثلة Deep Learning للصور الفضائية.
 - مفيد في: Computer Vision، Classification، Detection، Segmentation وغيرها.
 - طريقة الاستخدام: لا تقرأ بالكامل؛ استخدم Search عندما تحتاج technique معينة.
 - مناسب لمين؟ الفرق التي وصلت إلى مرحلة الـ implementation.
-

ثالثاً: مصادر بحث وإلهام (Optional)

15. FreeDSM

[FreeDSM — arXiv](#)

- النوع: Research Paper
- الهدف: إعطاء مثال على مشروع يجمع بين IoT و AI.

- الفائدة: فهم كيف يمكن تحويل مشكلة واقعية إلى نظام يعتمد على AI.
 - مناسب لمين؟ الفرق المتقدمة التي تريد Inspiration أو فكرة عن Architecture.
 - متى تستخدمه؟ قبل أو أثناء الهاكاثون.
 - لا يُنصح به: كمصدر تعلم أساسي للمبتدئين.
-

16. LightViz

[LightViz — arXiv](#)

- النوع: Research Paper / Project Inspiration
- الهدف: إعطاء مثال على استخدام التكنولوجيا لمراقبة وتحليل التلوث الضوئي.
- الفائدة: يساعد الفرق على رؤية مثال واقعي يربط البيانات والمراقبة والتحليل.
- مناسب لمين؟ الفرق التي تعمل على Light Pollution أو مشاريع مشابهة.